



NOVEMBER 14, 2025

MEMORIA DE TRABAJO DE ACTIVIDADES

1 Y 2


13MBID – METODOLOGÍAS DE GESTIÓN Y DISEÑO DE PROYECTOS BIG
DATA

JUAN FRANCISCO MATEO GARRIDO



Actividades Prácticas - Aplicando técnicas ágiles para la gestión de proyectos de ciencia de datos

El presente documento es una planilla que se utilizará para el desarrollo de la documentación correspondiente a las Actividades Prácticas I y II. El contenido será guiado según las fases y actividades de la metodología CRISP-DM en la integración planteada con DataOps y MLOps.



[A] Comprensión del negocio

Determinar los objetivos de la Organización

Las autoridades de una entidad financiera desean determinar la probabilidad de que un cliente acepte realizar un depósito a plazo con base en campañas de marketing telefónico que son realizadas con frecuencia.

Se quiere identificar qué acciones serían más efectivas y sobre qué tipos de clientes para aumentar la tasa de apertura de este tipo de depósitos, además de medir la tasa de éxito que tienen las campañas que se vienen realizando.

--

A partir de contar con una versión inicial del proyecto, se pasará a considerar como objetivo lograr implementar en producción al mismo para que pueda ser utilizado por sus usuarios finales.

En este proceso se deberá asegurar la calidad en general del proyecto desde cuestiones como:

- Versionado de los datos
- Reproducción de la experimentación y transformaciones que sean implementadas
- Registro de la experimentación y sus resultados
- Comparación de resultados entre diferentes técnicas
- Monitoreo de utilización del producto

--

Evaluación de la situación

Se cuenta con los siguientes recursos para la ejecución del proyecto:

- Los **datos** de los clientes que fueron objetivo de las campañas en cuestión junto a una serie de indicadores socioeconómicos de índole general.
- Se cuenta con el **personal** adecuado para la ejecución de las tareas involucradas en el proyecto.
- Se cuenta con un **experto en el dominio** para abordar dudas o cuestiones de detalladas que pudieran surgir.
- Se cuenta con las **herramientas** tanto software como hardware para el desarrollo y despliegue de los productos que pudieran surgir del proyecto.

El problema de la situación actual radica en el alto costo de estas campañas de marketing y la baja tasa de conversión que tienen.

--

Se cuenta, para esta segunda etapa, con los archivos de la experimentación que han sido generados para el proyecto durante la construcción de la primera versión de su producto resultante (el modelo de predicción) y los resultados de su utilización en un nuevo dataset.

--

Determinación de los objetivos del proyecto

Considerando los datos disponibles, los objetivos planteados en esta etapa de trabajo son:

- Generar un producto de datos orientado a la **predicción** de qué clientes aceptarían la oferta de apertura de un depósito de estas características.

--

Considerando una segunda etapa del proyecto, se plantea su objetivo a continuación:

- Implementar prácticas originadas en los modelos de DataOps y MLOps para automatizar ciertas cuestiones del proyecto y permitir la replicación de los resultados del mismo a lo largo del tiempo.

--

Definir plan del proyecto (tareas, recursos, etc)

Se determinan los siguientes entregables del proyecto:

- EDA
- Modelo inicial
- Métricas de evaluación del modelo
- Resultados parciales sobre un dataset nuevo

Se ha elaborado una versión inicial (MVP) del producto solicitado por el negocio. El mismo deberá ser desplegado para su utilización en la operatoria comercial mencionada.

--

A continuación, se agregan los enlaces relacionados con la gestión de tareas del proyecto en Github Projects, así como al repositorio donde se encuentran los archivos. Adicionalmente, se añaden evidencias del tablero de backlog generado:

- Github Projects: [13MBID-ABR2526-Proyecto](#)
- Repositorio Github: [13MBID_Porftolio_2526](#)

Iteration 1 0 Estimate: 30 Oct 07 - Oct 16 ...							
1	☑ Determinar los objetivos de la organización #1	Comprensión del negocio	S	Iteration 1	1	Done	MigasToulouse
2	☑ Evaluación de la situación #2	Comprensión del negocio	M	Iteration 1	2	Done	MigasToulouse
3	☑ Determinación de los objetivos de ciencia de datos #3	Comprensión del negocio	M	Iteration 1	3	Done	MigasToulouse
4	🔄 Definir plan del proyecto #4	Comprensión del negocio	L	Iteration 1	5	In progress	MigasToulouse
5	🔄 Recolección de datos iniciales #5	Comprensión de los datos	S	Iteration 1	2	Todo	MigasToulouse
6	🔄 Descripción de los datos #6	Comprensión de los datos	M	Iteration 1	2	Todo	MigasToulouse
7	🔄 Exploración de datos #7	Comprensión de los datos	M	Iteration 1	3	Todo	MigasToulouse
8	🔄 Verificación de la calidad de los datos #8	Comprensión de los datos	L	Iteration 1	3	Todo	MigasToulouse
9	🔄 Selección de datos #9	Preparación de los datos	S	Iteration 1	2	Todo	MigasToulouse
10	🔄 Limpieza de los datos #10	Preparación de los datos	M	Iteration 1	2	Todo	MigasToulouse
11	🔄 Construcción de datos #11	Preparación de los datos	M	Iteration 1	2	Todo	MigasToulouse
12	🔄 Integración de los datos #12	Preparación de los datos	S	Iteration 1	1	Todo	MigasToulouse
13	🔄 Formateo de los datos #13	Preparación de los datos	M	Iteration 1	2	Todo	MigasToulouse
+ Add item							
Iteration 2 0 Estimate: 0 Oct 17 - Nov 06 ...							
14	🔄 Selección de la técnica de modelado #14	Modelado		Iteration 2		Todo	
15	🔄 Generación de un plan de pruebas #15	Modelado		Iteration 2		Todo	
16	🔄 Construcción del modelo #16	Modelado		Iteration 2		Todo	
17	🔄 Evaluación del modelo #17	Modelado		Iteration 2		Todo	
18	🔄 Evaluación de los resultados #18	Evaluación		Iteration 2		Todo	
19	🔄 Proceso de revisión #19	Evaluación		Iteration 2		Todo	
20	🔄 Determinación de futuras tareas #20	Evaluación		Iteration 2		Todo	
21	🔄 Plan de implementación #21	Despliegue		Iteration 2		Todo	
22	🔄 Supervisión y Mantenimiento #22	Despliegue		Iteration 2		Todo	
23	🔄 Informe Final #23	Despliegue		Iteration 2		Todo	
24	🔄 Revisión del proyecto #24	Despliegue		Iteration 2		Todo	

[B] Comprensión de los datos

Recolección de datos iniciales

Se cuenta con un dataset exportado desde los sistemas transaccionales del cliente en su operatoria de marketing y vinculación con el objetivo de la revisión. Este se encuentra disponible en formato .csv con las siguientes características:

- Tiene 21 atributos.
- Tiene una (1) variable objetivo que indica si se ha realizado o no el depósito “y”.
- Totaliza más de 40 mil filas.

--

Se han versionado los dos datasets iniciales (completo y datos nuevos sin etiquetar) utilizando la librería DVC.

Estos cambios han sido confirmados en el repositorio del proyecto. Se mantuvo sin cambios la estructura y dimensionalidad de los archivos.

--

Descripción de los datos

Se describen las características principales del dataset:

Datos del cliente bancario

- age: edad (numérica)
- job: tipo de trabajo (categórica: admin., blue-collar, entrepreneur, housemaid, management, retired, self-employed, services, student, technician, unemployed, unknown)
- marital: estado civil (categórica: divorced, married, single, unknown)
- education: nivel educativo (categórica: basic.4y, basic.6y, basic.9y, high.school, illiterate, professional.course, university.degree, unknown)
- default: ¿tiene créditos en default? (yes, no, unknown)
- housing: ¿tiene préstamo hipotecario? (yes, no, unknown)
- loan: ¿tiene préstamo personal? (yes, no, unknown)

Datos de la última campaña

- contact: tipo de contacto (cellular, telephone)
- month: mes del último contacto (jan, feb, mar, ..., nov, dec)
- day_of_week: día de la semana (mon, tue, wed, thu, fri)
- duration: duración del último contacto en segundos (numérica)

Nota: este atributo influye fuertemente en el resultado. No debe usarse para modelos predictivos realistas, ya que solo se conoce después de la llamada.

Otros atributos

- campaign: número de contactos en esta campaña (numérica)
- pdays: días transcurridos desde el último contacto en campañas anteriores (numérica; 999 = nunca contactado)
- previous: número de contactos previos a esta campaña (numérica)
- poutcome: resultado de la campaña anterior (failure, nonexistent, success)

Contexto social y económico

- emp.var.rate: tasa de variación del empleo – indicador trimestral (numérica)
- cons.price.idx: índice de precios al consumidor – indicador mensual (numérica)
- cons.conf.idx: índice de confianza del consumidor – indicador mensual (numérica)
- euribor3m: tasa Euribor a 3 meses – indicador diario (numérica)
- nr.employed: número de empleados – indicador trimestral (numérica)

Variable objetivo

- y: ¿el cliente contrató un depósito a plazo? (yes, no)

--

Se mantiene sin cambios el dataset del proyecto.

--

Exploración de datos

En la exploración inicial se ha identificado principalmente un marcado desbalance en el atributo target, este refleja que muy pocos clientes aceptan la apertura de un depósito a plazo.

Se deberá considerar esta situación en la generación de un modelo de predicción.


--

En esta instancia se ha generado un nuevo *script* para que las operaciones de visualización de las características básicas de los datos puedan ser integradas a un *pipeline*.


Como resultado, el *script* genera gráficos en el directorio **docs/figures** del repositorio.

A continuación, se agregan algunos gráficos de interés:


- Distribución de valores del atributo objetivo (“y”)




- Distribución de valores del atributo “education” (nivel educativo alcanzado)




- Distribución de los valores del atributo 'job' (tipo de trabajo)




- Distribución del atributo 'loan' (préstamos personales)



- Distribución del atributo 'housing' (préstamos hipotecarios)



- Matriz de correlación entre variables del dataset



También se ha añadido en el mencionado *script* una generación de reporte del análisis exploratorio de datos (EDA) que queda almacenado en **docs/reports**, bajo el nombre de “EDA_reporte.html”. Una muestra es la siguiente:

Overview

Brought to you by YData

Overview

Alerts17

Reproduction

Dataset statistics

Number of variables	21
Number of observations	41188
Missing cells	0
Missing cells (%)	0.0%
Duplicate rows	12
Duplicate rows (%)	< 0.1%
Total size in memory	26.8 MiB
Average record size in memory	682.4 B


Variable types

Numeric	10
Categorical	10
Boolean	1

Variables

Select Columns ▾

age			
Real number (R)			
Distinct	78	Minimum	17
Distinct (%)	0.2%	Maximum	98
Missing	0	Zeros	0
Missing (%)	0.0%	Zeros (%)	0.0%
Infinite	0	Negative	0
Infinite (%)	0.0%	Negative (%)	0.0%
Mean	40.02406	Memory size	321.9 KiB



More details

Verificación de la calidad de los datos

Se ha verificado que algunas variables categóricas presentan valores faltantes representados como "**unknown**". Se ha considerado que esto no es una categoría en sí misma y se determinó que serán considerados como valores nulos.

A partir de esto, se dejó establecido un umbral de corte para la eliminación de atributos con valores nulos del 20% que fue empleado en la fase siguiente para la limpieza del dataset.

--

El análisis de calidad de los datos se basa en su utilidad para los objetivos del proyecto planteado, de esta manera, el enfoque de calidad en uso implica analizar las siguientes características:

Atributo	Observaciones
Exactitud	Grado en el que los datos de un atributo representan un valor verdadero.
Compleitud	Grado en el que los datos de un registro tienen valores asociados a cada una de sus columnas y el dataset en general aplica el mismo criterio para todas sus filas.
Consistencia	Grado en el cual los datos son coherentes con otros datos del contexto y con los conjuntos de datos disponibles para este proyecto.

Para cada dimensión definida, se plantean las evaluaciones a realizar en la siguiente tabla:

Atributo	Observaciones
Exactitud	- Composición del dataset (cantidad de columnas) - Composición del dataset (tipo e identificador de las columnas) - Comprobación de valores de atributos semánticamente no negativos como 'age' o 'duration'.
Compleitud	- No existencia de valores nulos (*) - No existencia de valores duplicados (*) (*) Posteriormente a la aplicación de las transformaciones
Consistencia	- Valores de los atributos en rangos preestablecidos por el experto en el dominio - Verificación de cumplimiento de reglas del negocio necesarias para el producto a generar - Valores de atributo 'age' dentro de un rango entre la mayoría de edad (18) y 100 años. - Todos los atributos categóricos contienen las etiquetas esperadas. - Comprobación de inconsistencias entre variables relacionadas (ej: no contactado, pero duración de llamada mayor que 0).

Descripción de la implementación de esta evaluación:

- Se implementaron una serie de tests automatizables (a través de código) utilizando la librería PyTest. En este caso se validaron aspectos de exactitud y completitud.
- Se implementaron una serie de tests utilizando la librería Great Expectations para validar cuestiones de consistencia.
- Todos los tests se han incorporado a un pipeline gestionado mediante la librería DVC que permite su ejecución en forma secuencial y la generación de un reporte en formato HTML que podría ser utilizado como documentación del caso.

Estas prácticas permitirán la replicación de la validación con nuevos conjuntos de datos a medida que el proyecto evolucione.

Los resultados obtenidos se presentan a continuación:

- Exactitud y completitud (test_dataquality)

test_results.html

Report generated on 12-Nov-2025 at 01:29:45 by `pytest-html` v4.1.1

Environment

Python	3.12.9
Platform	Windows-11-10.0.26200-SP0
Packages	- pytest: 8.4.2 - pluggy: 1.6.0
Plugins	- anyio: 4.8.0 - hydra-core: 1.3.2 - html: 4.1.1 - metadata: 3.1.1 - typeguard: 4.4.2

Summary

6 tests took 413 ms.

(Un)check the boxes to filter the results.

☒ 0 Failed

☒ 5 Passed

☒ 0 Skipped

☒ 1 Expected failures

☒ 0 Unexpected passes

☒ 0 Errors

☒ 0 Reruns

[Show all details](#) / [Hide all details](#)

Result	Test	Duration	Links
XFailed	test/test_dataquality.py::test_sin_duplicados	85 ms	
datos_banco = age job marital education default housing ... emp.var.rate cons.price.idx cons.conf.idx ... no yes ... -1.1 94.767 -50.8 1.028 expand [+] [41188 rows x 21 columns] @pytest.mark.xfail(reason="No romper el pipeline para demostrar funcionamiento.") def test_sin_duplicados(datos_banco: pd.DataFrame): """ Test para verificar que el DataFrame no contiene filas duplicadas. """ df = datos_banco # Descomenta la siguiente línea para activar el test. > assert df.duplicated().sum() == 0, \ f"El DataFrame contiene {df.duplicated().sum()} filas duplicadas." E AssertionError: El DataFrame contiene 12 filas duplicadas. E assert np.int64(12) == 0			
Passed	test/test_dataquality.py::test_esquema	127 ms	
Passed	test/test_dataquality.py::test_no_vacio	50 ms	
Passed	test/test_dataquality.py::test_sin_nulos	57 ms	
Passed	test/test_dataquality.py::test_cantidad_columnas	47 ms	
Passed	test/test_dataquality.py::test_rango_numerico_negativo	47 ms	

- Consistencia (test_data_gx)

test_gx_results.html

Report generated on 12-Nov-2025 at 01:51:34 by [pytest-html](#) v4.1.1

Environment

Python	3.12.9
Platform	Windows-11-10.0.26200-SP0
Packages	- pytest: 8.4.2 - pluggy: 1.6.0
Plugins	- anyio: 4.8.0 - hydra-core: 1.3.2 - html: 4.1.1 - metadata: 3.1.1 - typeguard: 4.4.2

Summary

17 tests took 70 ms.

(Un)check the boxes to filter the results.

☒ 4 Failed, ☒ 13 Passed, ☒ 0 Skipped, ☒ 0 Expected failures, ☒ 0 Unexpected passes, ☒ 0 Errors, ☒ 0 Reruns [Show all details](#) / [Hide all details](#)

Result 	Test	Duration	Links
Failed	test/test_data_gx.py::test_great_expectations_atomizado[age_range]	52 ms	
Failed	test/test_data_gx.py::test_great_expectations_atomizado[pdays_poutcome_consistency]	2 ms	
Failed	test/test_data_gx.py::test_great_expectations_atomizado[pdays_previous_consistency]	1 ms	
Failed	test/test_data_gx.py::test_great_expectations_atomizado[pdays_duration_consistency]	1 ms	
Passed	test/test_data_gx.py::test_great_expectations_atomizado[job_values]	2 ms	
Passed	test/test_data_gx.py::test_great_expectations_atomizado[marital_values]	1 ms	
Passed	test/test_data_gx.py::test_great_expectations_atomizado[education_values]	1 ms	
Passed	test/test_data_gx.py::test_great_expectations_atomizado[default_values]	1 ms	
Passed	test/test_data_gx.py::test_great_expectations_atomizado[housing_values]	1 ms	
Passed	test/test_data_gx.py::test_great_expectations_atomizado[loan_values]	1 ms	
Passed	test/test_data_gx.py::test_great_expectations_atomizado[contact_values]	1 ms	
Passed	test/test_data_gx.py::test_great_expectations_atomizado[month_values]	1 ms	
Passed	test/test_data_gx.py::test_great_expectations_atomizado[day_of_week_values]	1 ms	
Passed	test/test_data_gx.py::test_great_expectations_atomizado[campaign_range]	0 ms	
Passed	test/test_data_gx.py::test_great_expectations_atomizado[poutcome_values]	1 ms	
Passed	test/test_data_gx.py::test_great_expectations_atomizado[y_values]	1 ms	
Passed	test/test_data_gx.py::test_great_expectations_atomizado[duration_target_consistency]	2 ms	

--

[C] Fase de preparación de los datos

Selección de datos

En función de los resultados tanto del análisis de calidad de datos como de la exploración del dataset realizada, se ha determinado que los siguientes atributos serán eliminados:

- **“default”**: no presentaba variedad en los datos con una clase teniendo el 99.9% de la frecuencia en el dataset, además de presentar un alto valor de filas nulas (>20%).
- **“pdays”**: presenta una variedad muy baja estableciéndose el valor “999” un 96.3% de las ocasiones. Además, demuestra incoherencia con la variable “duration” ya que el 99.99% de las filas que toman el valor “999” en “pdays” tienen una “duration” mayor que 0. La información de haber sido contactado queda contenida en “previous”.

Limpieza de los datos

En esta actividad se aplicaron los filtros a nivel de filas que se detallan a continuación:

- Eliminación de filas duplicadas (12 casos)
- Eliminación de filas con valores nulos, tras convertir “Unknown” a valores nulos (2943 casos)

Integración de los datos y Construcción de datos

En este escenario no ha sido necesario la integración de datos, sin embargo se ha construido un nuevo atributo “contacts_diff” que representa la diferencia de contactos entre la campaña actual y la anterior.

Formateo de los datos

Finalizadas las operaciones de transformación de los datos, se ha obtenido un nuevo dataset sobre el cual se aplicaron operaciones de normalización y procesamiento para optimizar la fase de entrenamiento posterior de los modelos a generar.

- Binarización numérica de aquellas columnas que solo tienen como posibles etiquetas “yes” o “no”.
- Conversión de la columna “nr.employed” a valores enteros, ya que un punto flotante en personas no tiene sentido.
- Se sustituye “.” por “_” para aplicar *snake_case* en los atributos afectados.

--

Transformaciones realizadas en función a lo establecido en la libreta original:

- Sustitución de “.” por “_”.
- Eliminación de columna “default”.
- Eliminación de filas duplicadas.
- Se reemplazaron los valores “Unknown” por “NaN”.
- Se eliminaron las filas con valores nulos.
- Se eliminaron las filas duplicadas.

Además se añaden las siguientes transformaciones complementarias:

- Eliminación de la columna “pdays”.
- Creación de atributo “contacts_diff”
- Cambio de tipo en “nr_employed” de punto flotante a entero.

Las dimensiones del dataset resultante son:

- Cantidad de filas finales: 38232
- Cantidad de columnas finales: 20

Se ha generado un script para estas tareas y el mismo se ha integrado al pipeline generado en la fase previa para visualización y evaluación de calidad de los datos.

[D] Modelado

Selección de la técnica de modelado

En función de los objetivos del proyecto, se seleccionaron las siguientes técnicas para conformar el modelo de predicción requerido como MVP del proyecto:

- Regresión Logística
- LinearSVC
- KNN
- Árboles de decisión
- Entre otros

Como técnica complementaria se ha determinado utilizar validación cruzada.

--

En este caso, se va a utilizar una libreta de jupyter para el registro de la experimentación real con la modificación de integrar la misma a la librería MLFlow para que se dejen evidencias de:

- Técnicas utilizadas
- Parametrización
- Valores del dataset
- Resultados obtenidos

--

Generación del plan de pruebas

En este caso, el enfoque a utilizar será el siguiente:

- División de 80% para entrenamiento y 20% para testeo
- Aplicación de sub muestreo por la situación de desbalance entre clases.

--

Se va a aplicar el mismo criterio de la actividad anterior haciendo uso de MLFlow para el registro de la experimentación que fuera realizada. Los resultados quedarán disponibles en el mismo directorio del repositorio que contiene el código del proyecto.

En las siguientes tablas se documenta el detalle de la experimentación que ha sido registrada igualmente en mlflow:

- Decision Tree Classifier

Parameters (17)		Metrics (12)	
Search parameters		Search metrics	
Parameter	Value	Metric	Value
balancing_method	undersampling	cv_accuracy_mean	0.6763542399480491
ccp_alpha	0.0	cv_accuracy_std	0.008719770996802654
class_weight	None	cv_f1_mean	0.6985293346823485
criterion	gini	cv_f1_std	0.009621813810998026
cv_folds	5	cv_precision_mean	0.6560877951368526
max_depth	None	cv_precision_std	0.013438451434529432
max_features	None	cv_recall_mean	0.7425536236594085
max_leaf_nodes	None	cv_recall_std	0.013976273432259762
min_impurity_decrease	0.0	test_accuracy	0.567150516542435
min_samples_leaf	1	test_f1	0.17620706819313092
min_samples_split	2	test_precision	0.11177770760972529
min_weight_fraction_leaf	0.0	test_recall	0.41598119858989424
monotonic_cst	None		
random_state	None		
splitter	best		
test_samples	7647		
train_samples	5438		

- Logistic Regression

Parameters (19)		Metrics (12)	
Search parameters		Search metrics	
Parameter	Value	Metric	Value
balancing_method	undersampling	cv_accuracy_mean	0.5275792791817739
C	1	cv_accuracy_std	0.021657555614915457
class_weight	None	cv_f1_mean	0.5240248696605045
cv_folds	5	cv_f1_std	0.01387567739619907
dual	False	cv_precision_mean	0.5289513830451897
fit_intercept	True	cv_precision_std	0.02426464066453379
intercept_scaling	1	cv_recall_mean	0.5196809663091757
l1_ratio	None	cv_recall_std	0.009804504539137305
max_iter	100	test_accuracy	0.5238655681966784
multi_class	deprecated	test_f1	0.11989364273628234
n_jobs	None	test_precision	0.07547169811320754
penalty	l2	test_recall	0.29142185663924797
random_state	1		
solver	liblinear		
test_samples	7647		
tol	1e-09		
train_samples	5438		
verbose	0		
warm_start	False		

- Linear SVC

Parameters (16)		Metrics (12)	
Search parameters		Search metrics	
Parameter	Value	Metric	Value
balancing_method	undersampling	cv_accuracy_mean	0.5279469262405974
C	1.0	cv_accuracy_std	0.020099604705501144
class_weight	None	cv_f1_mean	0.5245425903575143
cv_folds	5	cv_f1_std	0.012621154408678358
dual	auto	cv_precision_mean	0.5292093858020459
fit_intercept	True	cv_precision_std	0.022586130395333807
intercept_scaling	1	cv_recall_mean	0.520415583360416
loss	squared_hinge	cv_recall_std	0.009210601366036826
max_iter	10000	test_accuracy	0.5271348241140317
multi_class	ovr	test_f1	0.11761835041483651
penalty	l2	test_precision	0.07422235910070835
random_state	None	test_recall	0.28319623971797886
test_samples	7647		
tol	0.001		
train_samples	5438		
verbose	0		

- K-Nearest Neighbors

Parameters (12)		Metrics (12)	
Search parameters		Search metrics	
Parameter	Value	Metric	Value
algorithm	auto	cv_accuracy_mean	0.5671219695329833
balancing_method	undersampling	cv_accuracy_std	0.016650119017254727
cv_folds	5	cv_f1_mean	0.5790902244677432
leaf_size	30	cv_f1_std	0.017294092057285566
metric	minkowski	cv_precision_mean	0.5635623214868082
metric_params	None	cv_precision_std	0.015750910887672446
n_jobs	None	cv_recall_mean	0.5958225002708265
n_neighbors	7	cv_recall_std	0.023660618383540714
p	2	test_accuracy	0.5200732313325487
test_samples	7647	test_f1	0.18984547461368653
train_samples	5438	test_precision	0.11687958684425115
weights	uniform	test_recall	0.5052878965922444

--

Construcción del Modelo

Se han realizado pruebas con la siguiente configuración:

- LogisticRegression
 - C=1,
 - penalty='l2',
 - solver='liblinear',
 - random_state=1,
 - max_iter=100,
 - tol=0.000000001
- LinearSVC
 - max_iter=10000,
 - tol=0.001
- KNeighborsClassifier
 - n_neighbors=7
- DecisionTreeClassifier
 - Sin cambios en parámetros por defecto

--

En esta actividad, lo que se ha realizado es la implementación de un script para realizar la generación exportación del modelo con la técnica seleccionada ante la evaluación de la experimentación (Árbol de Decisión). Este script implementa:

- Separación de los datos en conjuntos de entrenamiento y prueba
- Implementación del balanceo de clases por submuestreo
- Entrenamiento del modelo
- Exportación a un archivo .pkl del modelo en cuestión
- Registro de todas las operaciones en mlflow
- Exportación a un archivo .json de las métricas obtenidas ante el entrenamiento.

--

Evaluación del modelo

Resultados de las pruebas realizadas

- DecisionTreeClassifier
 - cross validation f1 scores:
 - 0.7034120734908137
 - 0.6858638743455497
 - 0.6960203217612193
 - 0.7011197243755384
 - 0.6927083333333334
 - cross validation f1 mean 69.85293346823485
 - cross validation f1 std 0.009621813810998026
 - cross validation recall scores
 - 0.7463235294117647
 - 0.7334558823529411
 - 0.7555147058823529

- 0.7550644567219152
 - 0.7426470588235294
 - cross validation recall mean 74.25536236594085
 - cross validation recall std 0.013976273432259762
- LogisticRegression
 - cross validation f1 scores:
 - 0.5289256198347108
 - 0.5110294117647058
 - 0.5449275362318841
 - 0.5288197621225984
 - 0.5064220183486239
 - cross validation f1 mean 52.40248696605045
 - cross validation f1 std 0.01387567739619907
 - cross validation recall scores:
 - 0.5294117647058824
 - 0.5110294117647058
 - 0.5183823529411765
 - 0.5322283609576427
 - 0.5073529411764706
 - cross validation recall mean 51.96809663091757
 - cross validation recall std 0.009804504539137305
- LinearSVC
 - cross validation f1 scores:
 - 0.5302752293577981
 - 0.5142332415059688
 - 0.5438765670202508
 - 0.526508226691042
 - 0.5078196872125115
 - cross validation f1 mean 52.45425903575143
 - cross validation f1 std 0.012621154408678358
 - cross validation recall scores:
 - 0.7463235294117647
 - 0.7334558823529411
 - 0.7555147058823529
 - 0.7550644567219152
 - 0.7426470588235294
 - cross validation recall mean 52.0415583360416
 - cross validation recall std 0.009210601366036826
- KNeighborsClassifier
 - cross validation f1 scores
 - 0.577736890524379

- 0.5862377122430742
- 0.5530776092774309
- 0.6059544658493871
- 0.5724444444444444
- cross validation f1 mean 57.90902244677432
- cross validation f1 std 0.017294092057285566
- cross validation recall scores:
 - 0.5772058823529411
 - 0.6029411764705882
 - 0.5698529411764706
 - 0.6372007366482505
 - 0.5919117647058824
- cross validation recall mean 59.58225002708265
- cross validation recall std 0.023660618383540714

--

[E] Evaluación

Evaluación de los resultados

En cuanto al modelo de predicción, se evaluaron diferentes algoritmos de clasificación mediante validación cruzada, utilizando las métricas f1-score y recall. Los resultados promedio obtenidos fueron los siguientes:

Modelo	F1 mean	F1 std	Recall mean	Recall std
Logistic Regression	52.40%	0.0139	51.97%	0.0098
LinearSVC	52.45%	0.0126	52.04%	0.0092
KNeighborsClassifier	57.91%	0.0173	59.58%	0.0237
DecisionTreeClassifier	69.85%	0.0096	74.27%	0.0140

El mejor desempeño se obtuvo con el DecisionTreeClassifier, que superó ampliamente al resto de los modelos en ambas métricas.

Esto indica que el árbol de decisión logra capturar mejor las relaciones no lineales presentes en los datos y ofrecer un equilibrio adecuado entre precisión y sensibilidad en la predicción de la aceptación del depósito a plazo.

--

Las pruebas realizadas han sido replicadas y se mantuvo en esta instancia de trabajo la decisión original del proyecto. Para garantizar que ante un re-entrenamiento del modelo el mismo mantenga su rendimiento (en términos de las métricas empleadas para su evaluación) se ha generado un nuevo **caso de prueba (test de regresión)** para verificar que los resultados de la generación del modelo no presenten una variación significativa con respecto a las métricas de su evaluación original.

--

Proceso de revisión

En función de los datos disponibles de los clientes y las campañas realizadas, se ha podido generar un producto de datos que conforma el resultado inicial del proyecto (MVP).

En esta primera versión, el modelo de predicción se considera adecuado y se ha registrado todo el proceso de desarrollo tanto en la modificación del dataset original como en la experimentación realizada en el presente documento.

--

En la continuidad del proyecto se ha avanzado en las siguientes tareas:

- Las operaciones sobre datos (visualización, transformación y verificación de calidad) han sido pasadas a scripts que responden a lo implementado en las libretas de experimentación.
- Se ha generado un flujo de operaciones (pipeline) con la librería DVC para automatizar y orquestar este conjunto de operaciones a partir de estos scripts.
- Se ha registrado toda la experimentación realizada y la generación del modelo del árbol de decisión para el escenario en la librería MLFlow.
- Se han generado dos productos para publicar el MVP:
 - Una API implementada con FastAPI que permite utilizar el modelo de predicción generado
 - Una aplicación web con Streamlit que permite a un usuario final generar predicciones sobre datos nuevos utilizando el modelo disponible a través de la API.

--

Determinación de futuras tareas

Contando con el MVP construido, se pueden establecer las siguientes líneas de trabajo para un futuro:

- Determinar viabilidad de implementación de mejoras en las prácticas de gestión de los datos y en el proceso en sí para asegurar la capacidad de reproducción de los mismos.
- Adaptar los procesos para lograr automatización de algunas prácticas.
- Optimizar los hiperparámetros del modelo de árbol de decisión y evaluar variantes como Random Forest o XGBoost para aumentar la capacidad de generalización.

--

Como tareas a futuro podemos mencionar:

- Implementación de instancias de monitoreo de la solución propuesta (MVP) en cuanto a uso, resultados obtenidos y otras métricas que se consideren adecuadas.
- Hacer uso de sistemas de búsqueda de hiperparámetros que permitan encontrar la mejor configuración de los modelos para la selección.
- Añadir un chequeo de consistencia de los datos, ya que algunas variables como “duration” y “contacted_before” no pueden tener valores libremente elegidos si quiere mantener la coherencia.
- Sistema de imputación de datos, en vez de la eliminación directa para mantener la cantidad de información introducida.

- El test de regresión debería fallar solo ante un modelo que tiene unos resultados peores que el ya establecido. Encontrar un mejor modelo es siempre mejor opción.
- Tratamiento de los scripts, backend y frontend como lenguaje orientado a objetos, incluyendo el polimorfismo para facilitar la expansión de funcionalidades en el sistema.
- Hacer uso de herramientas como Jenkins que permitan el Continuous Integration sobre el código y así evitar un merge en el repositorio que provoque la caída del servicio.
- Implementar un test de calidad del código que permita verificar si existe código muerto, vulnerabilidades o si el estilo entorpece el desarrollo.
- Automatización de ingesta de datos hacia la API que permita tomar periódicamente la información y realizar las predicciones sin necesidad de introducción manual.
- Generar un dashboard que permita ver los resultados por campaña, haciendo una comparativa entre valores predichos y reales que servirán también para estudiar cómo mejorar el modelo de predicción.

Estos son solo ejemplos de tareas, pero realmente se podrían incluir muchas más.

--

[F] Despliegue / Implementación

Plan de implementación

Las autoridades de la entidad han determinado continuar con sucesivas iteraciones del proyecto para refinar el producto generado y que aporte mayor valor al negocio, cumpliendo con los objetivos inicialmente planteados.

Es por esto, que el conjunto de datos será actualizado periódicamente a partir de los sistemas fuente que corresponda. De esta manera, la entidad se asegura que las herramientas generadas se mantengan actualizadas.

--

Con los productos generados para el uso del modelo de predicción por parte de los usuarios finales, se ha determinado realizar el despliegue de los mismos en un entorno web. Los productos se encuentran accesibles desde los siguientes enlaces:

- API: <https://api-13mbid-m21x.onrender.com>
- Aplicación web: <https://13mbid-apr2526.streamlit.app>

Captura de la API:

Modelo de Clasificación de Clientes Bancarios 1.0.0 OAS 3.1

/openapi.json

API para predecir si un cliente bancario suscribirá un depósito a plazo fijo.

default

GET / Root

GET /health Health

POST /predict Predict

Realiza una predicción basada en los datos del cliente bancario proporcionados.

Parameters

No parameters

Request body required application/json

Edit Value | Schema

```
{
  "age": 35,
  "campaign": 1,
  "cons_conf_id": -36.4,
  "cons_price_id": 93.994,
  "contact": "cellular",
  "contacted_before": 1,
  "contacts_diff": 1,
  "day_of_week": "mon",
  "duration": 300,
  "education": "university.degree",
  "emp_var_rate": 1.1,
  "euribor3m": 4.857,
  "housing": 1,
  "job": "technician",
  "loan": 0,
  "marital": "married",
  "month": "may",
  "nr_employed": 5191,
  "predicted": "no"
}
```

Execute

Responses

Code	Description	Links
200	Successful Response	No links

Media type
application/json

Controls Accept header:

Example Value | Schema

```
{
  "prediction": 0,
  "probability": {},
  "model_info": {}
}
```

Captura de la aplicación web.

URL de la API

http://localhost:8000

Estado de la API

API está en línea :green_circle:

Deploy

Predicción de suscripción a un producto bancario

Esta aplicación utiliza un modelo de Machine Learning para predecir si un cliente suscribirá un depósito a plazo fijo basado en sus características personales y de contacto.

[Predicción Individual](#) [Información del Modelo](#)

Información del Cliente

Datos Personales	Datos de Contacto	Indicadores Económicos
Edad 30 - +	Tipo de contacto cellular	Tasa de variación del empleo 1.10 - +
Tipo de trabajo admin.	Mes de contacto aug	Índice de precios al consumidor 93.99 - +
Estado civil divorced	Día de la semana del contacto mon	Índice de confianza del consumidor -36.40 - +
Nivel educativo basic.4y	Duración de la llamada (segundos) 100 - +	Tasa Euribor a 3 meses 4.86 - +
¿Tiene hipoteca? 0 - no, 1 - si 0	Número de contactos en esta campaña 1 - +	Número de empleados 5191 - +
¿Tiene préstamo personal? 0 - no, 1 - si 0	Número de contactos en campañas anteriores 0 - +	
	Resultado de la campaña anterior failure	
	¿Fue contactado antes? 0 - no, 1 - si 0	
	Diferencia en número de contactos (actual - anterior) 0 - +	

Realizar predicción

Predicción realizada con éxito!

Resultado de la Predicción

El cliente probablemente suscribirá el depósito a plazo fijo: si

Probabilidades

Probabilidades de suscripción

Clase	Probabilidad
1	100.00%

Información del Modelo

```
{  "model_type": "DecisionTreeClassifier"  "preprocessor_type": "ColumnTransformer"}
```

Supervisión y Mantenimiento

Una vez que los productos pasen a ser utilizados por los usuarios finales que corresponda, se podrían realizar las siguientes acciones:

- Generar una herramienta de interacción para predicciones.
- Determinar automatización de controles para la gestión del proceso de entrenamiento.

--

En esta segunda instancia de trabajo se ha logrado implementar las herramientas necesarias para que los usuarios puedan interactuar con el modelo de predicción generado y lo hagan a través de la web.

Con respecto al segundo punto, se ha avanzado en la generación de un pipeline aplicable a las tareas de generación del dataset de entrenamiento para el modelo y su validación, así como también para la generación y versionado del modelo.

Resta implementar mediante acciones de seguimiento el monitoreo de la calidad de las predicciones del modelo para determinar las reglas de su actualización en caso de corresponder.

--

Informe Final

El presente documento, con modificaciones, será presentado a las autoridades de cada sector involucrado en la explotación del producto generado, a fin de que se puedan establecer acciones que faciliten su adopción en el día a día. De esta manera, se contribuye al logro de los objetivos planteados.

--

Los resultados de esta etapa del proyecto serán presentados ante las autoridades para que se pueda iniciar una etapa de verificación del modelo generado, considerando su rendimiento en comparación a los métodos actuales que utiliza la organización. De esta manera se podrá evaluar su efectividad y determinar pasos a seguir en la implementación del proyecto.

Además, se deberá hacer una revisión metodológica sobre el marco de trabajo Agile, en el que identificar aspectos a mejorar del proceso o el seguimiento del procedimiento por parte de los integrantes del proyecto, a fin de mejorar, ya sea con retrospectivas o de otra manera, la efectividad del marco de trabajo.

--

Revisión del proyecto

Una vez finalizada la generación del modelo de predicción, se ha probado el mismo con datos nuevos de clientes que aún no fueron evaluados en torno a la efectividad de las campañas de marketing y se obtuvieron los siguientes resultados que faltará validar contra los datos reales a fin de corroborar la efectividad del producto generado:

- Resumen de predicciones (9 casos):
 - Sí realizará un depósito: 4 clientes (44.4%)
 - No realizará un depósito: 5 clientes (55.6%)

--

Como elementos de la finalización de esta etapa de revisión del MVP del proyecto se presentan los siguientes resultados:

- Se mantuvieron los valores de predicciones con respecto a los datos nuevos (sin clasificación previa) obtenidos en la fase anterior mediante las herramientas generadas.
- Un registro de las actividades realizadas que permite la trazabilidad del trabajo seguido en este documento en Github Projects, cuyo enlace se encuentra en la sección *Definir plan del proyecto* que sigue la misma estructura que este documento.
- Se ha llevado a cabo un versionado de los datos y los elementos de ejecución de este proyecto a nivel técnico para mantener la integridad tanto de los datos, como de la trazabilidad del trabajo realizado. Se han utilizado 2 métodos:
 - Git – versionado de documentos
 - DVC – versionado de datos
- La generación de un repositorio que permite mantener la trazabilidad, el versionado y el trabajo colaborativo en Github. El enlace se encuentra en la sección *Definir plan del proyecto*.
- De las distintas etapas definidas en este proyecto, los elementos clave que permiten la ejecución exitosa son:

- Modificación y generación de nueva libreta de experimentación: *MD01_Experimentacion.ipynb* y *MD01_Experimentacion_MLFlow.ipynb*
- scripts de tratamiento de datos y entrenamiento: *data_preprocessing.py*, *data_visualization_and_EDA.py* y *train_model.py*
- Test para corroborar la correcta ejecución de cada script: *test_dataquality.py*, *test_data_gx.py*, *test_training.py*.
- Scripts que permiten mantener un servicio web de despliegue: *main.py* y *ui.py*
- De los archivos del punto anterior, se generan los siguientes productos:
 - Gráficos sobre la exploración de datos en *docs/figures*
 - Reporte EDA en *docs/reports*
 - Reporte de los tests en *docs/test_results*
 - Un listado de las transformaciones de preprocesado llamado *transformaciones_dataset.md* en *docs/*
 - El dataset preprocesado en *data/processed* como *bank-additional-full_preprocessed.csv*
 - El modelo y su preprocesador para producción llamados *decisión_tree_model.pkl* y *preprocessor.pkl* en *models/*
 - Las métricas del modelo *model_metrics.json* en *metrics/*
- Un servicio web básico como despliegue de la aplicación desarrollada.
- La memoria del trabajo que es, precisamente, este documento.

Como cuestiones a revisar para una siguiente iteración se mencionan:

- Una guía de actuación para el trabajo colaborativo en el repositorio de Github, que permita trabajar en ramas y mantener solo main como la rama de producción.
- La generación de un archivo que funcione a nivel de “inventario” que describa los documentos del proyecto, quién es responsable de ellos y con qué herramientas se relaciona.
- Revisiones de código basados en estándares como PEP para asegurar la calidad del trabajo realizado
- El establecimiento de reuniones para seguimiento del trabajo y las expectativas de cada sprint. Además, se deben generar minutas por trazabilidad.
- Una reunión de retrospectiva que permita realizar una mejora continua sobre la forma de trabajar para aumentar la eficiencia del proceso.
- La definición formal de tests sobre los archivos programáticos, distinguiendo su nivel de criticidad, funcionalidad y cobertura de código.
- La separación de repositorios entre la aplicación que sirve como servicio web y la parte más pura de la ciencia de datos. El repositorio de la aplicación deberá estar incluido dentro del repositorio general.
- Añadir un sistema de integración continua como Jenkins para verificar que la aplicación se construye y ejecuta correctamente previo a cualquier cambio en el código de producción.
- La exclusión de los datos en el repositorio para incluirlos en una plataforma destinada al guardado y gestión de los datos, como por ejemplo MongoDB.
- Añadir un sistema de búsqueda de hiperparámetros para optimizar el rendimiento del modelo.
- Mejorar el test de regresión, de manera que solo falle cuando el rendimiento empeora.
- Añadir la funcionalidad de entrenamiento automatizado, haciendo que el sistema ante la alerta de nuevos datos en el banco de datos pueda realizar todas las pruebas.

- Generar un dashboard que permita monitorear la evolución del rendimiento del algoritmo.
- Generar una línea cronológica de actuación de alto nivel sobre el proyecto, que permita tener una idea generalizada del trabajo pendiente.
- Etc.

A pesar de la larga lista, el proyecto se encuentra en un estado inicial y se podrían añadir más tareas que quedarían para otras iteraciones futuras.

--